# 看图识猫：检测分割与视觉大模型的同图比较

## 项目做什么

上传一张猫的照片，两条路线独立识别，各给出一个品种。传统路线另外画出检测框和分割轮廓；视觉大模型写出简短外观特征。支持Oxford-IIIT Pet的12种猫品种，多只猫时关注画面中面积最大的猫。

## 第二阶段的方法用在哪里

传统路线先用YOLO26n检测猫，再把检测框交给SAM2.1，取得主体轮廓。程序按主体范围加6%边距裁剪RGB图片，保留毛色和花纹，交给本项目微调的YOLO26s-cls分类器。没有猫框时返回未检测到猫，不强行给品种。

大模型路线在本机运行Qwen3-VL-4B-Instruct，通过Transformers SDK传入原图和固定任务说明。提示中列出12个品种代码，要求只返回一个品种和最多3条可见特征。两条路线互不传递答案。Qwen采用官方预训练参数；本项目训练的是猫品种分类器。

这里的注意力可以理解为：模型计算图像或文字中哪些部分彼此相关，再按相关程度汇总信息。我们调用开源模型的这项能力，完成图片加文字输入和结构化输出。OpenCV/Pillow负责读取、裁剪和轮廓展示，FastAPI提供本地图片上传接口。

## 数据怎么分

官方trainval中的猫分为950张训练图和238张验证图，官方测试保留1183张。训练来源图各生成原图和主体图两种视图，共1900张训练视图；验证集每张保留一张主体视图，共238张。两种训练视图来自同一张原图，不计成两张独立来源。跨集合SHA256重复为0。

在测试预测前，按固定随机种子20261101选出每个品种10张，共120张共同测试图。两条路线实际使用这同一清单，逐图保存输入摘要、输出、状态与耗时。训练、阈值和提示调整使用训练或验证数据，测试答案不进入推理提示。

## 训练过程

分类器以YOLO26s-cls通用预训练权重为起点，输出改为12类，微调参数。输入320像素，batch=8，workers=0，AdamW初始学习率0.0008，余弦衰减，最多40轮，按验证fitness保存最佳权重。上游fitness为Top-1与Top-5准确率的平均值，界面与本项目比较只展示一个品种和Top-1正确率。

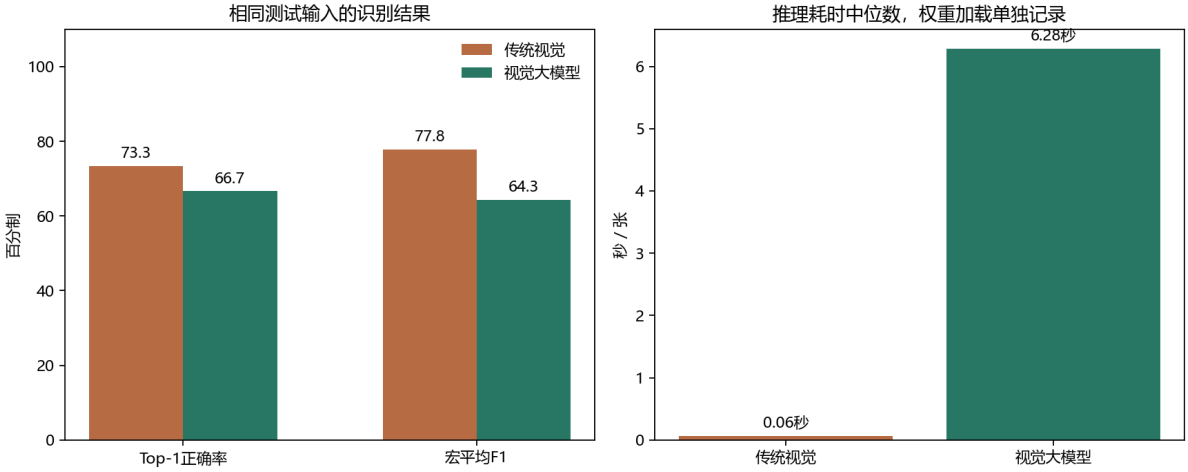
训练使用NVIDIA GeForce RTX 5080 Laptop GPU，PyTorch 2.9.1+cu128，CUDA 12.8。训练记录耗时约11.1分钟。此前中断的已完成轮次通过检查点接续，原检查点与日志保留。下载、训练和两路批量推理分开执行；训练每批同步GPU后等待0.05秒，推理也留出短暂停顿。运行错误会停止任务，不自动重试。

## 相同120张测试图片的结果

传统视觉：正确88/120，Top-1正确率73.33%，宏平均F1为0.7782。
视觉大模型：正确80/120，Top-1正确率66.67%，宏平均F1为0.6428。
传统视觉：105张输出品种，15张未检测到猫。
视觉大模型：113张返回有效结构，5次格式错误，2次返回其他品种。

每张图都计入总数，漏检、其他品种、格式错误和运行失败均不当成正确答案。宏平均F1先给每个品种计算一个综合分，再对12个品种取平均。

传统视觉推理耗时中位数0.06秒/张；视觉大模型6.28秒/张。权重加载与主动等待时间单独记录，网页首次运行还会花时间加载模型。单张图片上的分类分数是模型对这张图的输出，不是整组测试准确率；大模型没有生成百分比分数。




## 实际案例

Abyssinian_213：真实为阿比西尼亚猫；传统视觉给出阿比西尼亚猫，视觉大模型给出阿比西尼亚猫。
Birman_88：真实为伯曼猫；传统视觉给出伯曼猫，视觉大模型给出布偶猫。
Sphynx_37：真实为斯芬克斯猫；传统视觉给出未检测到猫，视觉大模型给出斯芬克斯猫。
Bombay_50：真实为孟买猫；传统视觉给出未检测到猫，视觉大模型给出俄罗斯蓝猫。

## 实现感悟

这次项目让我更关注识别流程中的每一步。分类器即使能认品种，前面的检测器漏掉猫，整条路线还是会失败，所以报告保留了未识别结果。把两条路线放到同一张图上，也能看到“说得清楚”和“品种判断正确”需要分别检查。

环境复现同样影响交付。项目用依赖版本、相对资源位置和数据参数组织运行；换电脑先恢复环境和权重，再启动服务。开发中发现中断下载留下了全零区域，文件长度仍然正常，最终靠官方SHA256发现并修复。后续保存权重时增加了落盘同步，并保留训练日志和检查点。

项目目前支持12类。传统分类器会把检测到的猫归入这12类之一；大模型可以返回其他品种。无毛猫、遮挡、复杂背景和相近品种值得继续补充样本。后续改进会优先检查检测漏失和具体混淆类别，再决定是否增加数据或调整模型。

## 参考和AI辅助

本项目参考Grounded-SAM-2的检测框引导分割流程、Pytorch-garbage-classify的训练/验证与图片接口组织，以及LAVIS的图像加问题调用方式。代码由AI辅助开发，训练与两路预测在本机实际运行，具体输出以保存的实验记录为准。

参考项目：https://github.com/IDEA-Research/Grounded-SAM-2
参考项目：https://github.com/Candy-CY/Pytorch-garbage-classify
参考项目：https://github.com/salesforce/LAVIS
数据来源：https://www.robots.ox.ac.uk/~vgg/data/pets/
Qwen官方模型：https://modelscope.cn/models/Qwen/Qwen3-VL-4B-Instruct

完整课程提要、视频索引、PDF原文、已有模型数据和历史日志随完整保留包保存。