看图识猫：检测分割、Transformer与视觉大模型

项目做什么

上传一张猫图，两条路线独立读取同一输入，各给出一个品种。传统视觉画出猫框和分割轮廓；本地视觉大模型补充简短外观特征。支持Oxford-IIIT Pet的12种猫。照片以一只主要猫为宜；多只猫品种不同时，整图和主体的判断可能不同。

第二阶段的方法

传统路线用YOLO26n定位猫，以检测框提示SAM2.1分割，再按主体范围加6%边距裁剪RGB图片。本次独立微调Swin-Tiny分类器。验证集比较原图、主体图及融合后，完整原图的结果最好，因此本版品种分类只使用原图；YOLO与SAM负责主体位置和轮廓展示。检测漏掉时，分类器继续看原图。共享的Transformer特征分别送给12类品种头和猫/狗物种头；物种头认为不是猫时不输出猫品种。

Swin把图像分成小块，在窗口内计算各块之间的关系，再通过移动窗口交换信息。这让模型能够结合耳形、脸部、毛色和花纹。我们从官方ImageNet通用权重开始微调，没有套用第一阶段已经训练好的权重。检测和SAM采用官方参数，本项目训练Swin骨干与两个输出头。

另一条路线是本地Qwen3-VL-4B-Instruct。Transformers SDK真正接收原图和固定的文字说明，返回单个品种与最多3条可见特征。提示、192个输出token上限、BF16和SDPA设置沿用旧版；两条路线不传递彼此答案。

为什么改这次流程

第一阶段88.84%对应全部1183张测试；取出旧共同120张，第一阶段97张正确（80.83%），旧第二阶段88张（73.33%）。旧第二阶段15张没有检测框，分类器没有运行。在其余105张检测成功的图片上，第一阶段认对85张，旧第二阶段认对88张；整条路线的主要损失发生在漏检门槛。在238张验证图上，旧硬门槛流程认对197张，同一旧分类器直接看原图认对212张。这次先修正定位失败就终止识别的流程，再升级分类器。

数据和训练

猫仍是950张训练原图、238张验证原图和1183张官方测试原图。训练随机使用猫原图或已有主体视图，两种视图不算两张独立来源。另从官方trainval中固定1000张狗作训练负例，500张狗作验证负例，旧检测实验用过的50张狗保留在验证侧。猫/狗训练来源共1950张；验证共738张。狗负例帮助区分猫与狗，其成绩不代表所有背景和物体的拒识能力。

输入224像素，batch8、workers0、CPU线程2。先冻结骨干训练2轮，再微调全部参数；AdamW，骨干学习率0.000015，头部0.0005，余弦衰减，品种标签平滑0.05，物种损失系数0.5。每批同步GPU后等待0.05秒。训练完成23轮，耗时13.5分钟；最佳检查点第15轮。选模只看验证集原图品种正确数，同分时优先狗误判少的检查点。

选模后在验证集一次比较原图/主体权重和水平翻转平均。本次主体权重0.00，水平翻转平均关闭，猫判断阈值0.5000。选择后的验证结果为231/238，1/500张狗误报成猫。权重以FP16保存方便入库，推理载入FP32模型；导出后重新运行了上述验证。原FP32与每轮权重全部保留。

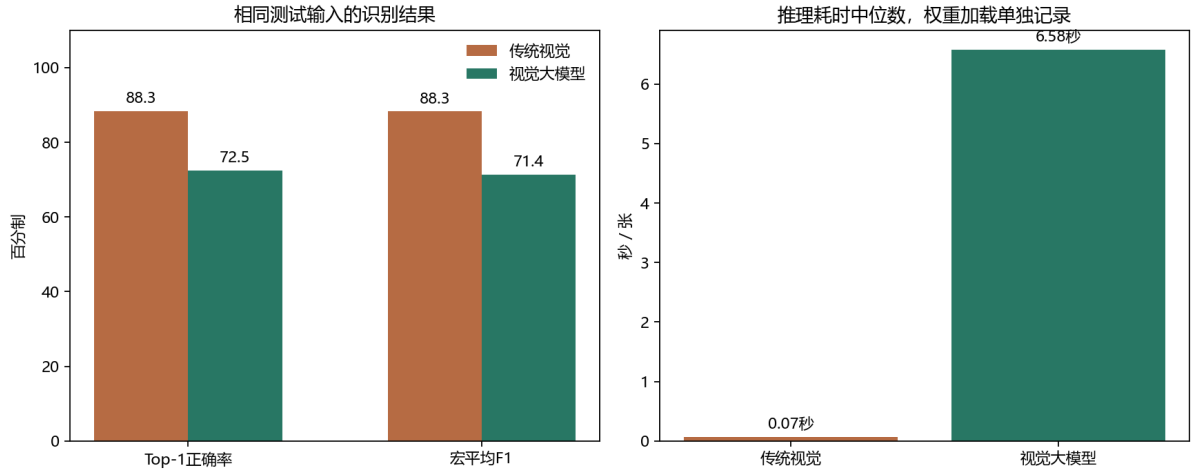
相同120张新测试图片

训练开始前固定种子20261102，每类10张，从未进入旧共同120张的官方测试图中抽取。旧测试只用于排查和回归，这批新图用于本次独立测试；参数冻结后不再根据测试结果调整。

改进传统视觉：106/120，Top-1正确率88.33%，宏平均F1 0.8828。
本地视觉大模型：87/120，Top-1正确率72.50%，宏平均F1 0.7139。
第一阶段已保存的同图预测：103/120，正确率85.83%，只读取保存结果，没有加载第一阶段模型。

改进传统视觉的未给品种数0；视觉大模型格式错误3次，其他品种1次。每张都计入分母，失败不删除。单张分类分数表示模型对这张图的输出，整组测试正确率需要逐张对照真实标签后统计。

分类器只看原图的官方全量猫测试：1067/1183，正确率90.19%；另测100张官方测试狗图，0张被误判成猫。全量含此前排查过的旧120张；本轮未用于排查的新共同120张成绩单独列出。这个全量成绩对应原图分类分支，带定位和轮廓展示的实际流程成绩以上面的共同120张为准。



实际案例

Abyssinian_81：真实阿比西尼亚猫；传统视觉阿比西尼亚猫，大模型阿比西尼亚猫。
Abyssinian_63：真实阿比西尼亚猫；传统视觉阿比西尼亚猫，大模型俄罗斯蓝猫。
Birman_50：真实伯曼猫；传统视觉暹罗猫，大模型伯曼猫。
Abyssinian_215：真实阿比西尼亚猫；传统视觉孟加拉猫，大模型英国短毛猫。

运行与实现体会

检测、分割提供位置和轮廓；本次品种判断保留完整原图，主体裁剪没有参与最终分类。

改进传统路线推理中位数0.07秒/张，视觉大模型6.58秒/张。权重加载和主动等待另记。下载、训练和两路推理依次执行，发生错误保存完整日志并停止，不自动重试或重启。

这次改动保留了检测与分割，让它们完成位置和轮廓展示。能否识别品种还要靠适合细粒度分类的特征，以及原图中完整的耳朵、脸部和花纹。验证集上的消融帮助找到了损失发生的位置，避免一看到分数低就盲目增加图片。后续补图应围绕相近品种、无毛猫、遮挡和多猫场景，并按来源隔开训练与测试。

环境使用独立Python环境和版本化依赖；资源按项目根目录寻找，外部数据通过参数传入。原始PDF、68集课程视频提要、参考仓库方法说明、旧版数据和日志都保留。第一阶段与第二阶段项目彼此独立。

参考和AI辅助

方法参考Grounded-SAM-2的检测框引导分割、Pytorch-garbage-classify的训练与验证组织、LAVIS的图文SDK调用。AI辅助编写和排查代码；报告中的训练、测试和逐图输出来自本机实际运行。

数据：https://www.robots.ox.ac.uk/~vgg/data/pets/
Swin：https://pytorch.org/vision/stable/models/swin_transformer.html
参考：https://github.com/IDEA-Research/Grounded-SAM-2
参考：https://github.com/Candy-CY/Pytorch-garbage-classify
参考：https://github.com/salesforce/LAVIS
Qwen：https://modelscope.cn/models/Qwen/Qwen3-VL-4B-Instruct